






Compression-based Language Complexity under Register Variation in Portuguese

Felipe Ribas Serras

Marcelo Finger

Instituto de Matemática, Estatística
e Ciência da Computação



Universidade de São Paulo

Questões de Pesquisa

01

Métricas baseadas em compressão são sensíveis à variação em registro no Português?

02


Essa variação mantém o *trade-off* entre métricas sintáticas e morfológicas, como observado para o Inglês?

03

Em que medida esses padrões de variação diferem ou se assemelham dos observados para o Inglês?


Agenda

- 01 Compression-Based Complexity Metrics
- 02 Register Variation and Data
- 03 Experimental Methodology and Statistical Procedures
- 04 Results and Analysis
- 05 Conclusions






 /frserras/register-complexity-pt




Métricas de Complexidade Linguística Baseadas em Compressão




Métricas de Compressão


- Métricas de complexidade linguística estrutural
- Quantificam grau de redundância e (ir)regularidade informacionais
- Funcionam em diferentes níveis de análise



Métricas de Compressão

-  Perturbar
-  Comprimir
-  Comparar





Métricas de Compressão

- Implementação: https://github.com/frserras/lang_complexity
(v1.0) (Serras et al 2024a)
 - $\{C_s, C_m, C_m^*\}$ (gzip, bzip2)



Variação em Registro



Variação em Registro

- Variação intralinguística e sincrônica
- Variações funcionais à situação da produção
- Caracterizadas por diferenças pervasivas e probabilística de propriedades léxico-gramaticais



Variação em Registro

- Dados :
 - */carolina-c4ai/carol-domain-sents*
 - Dataset de classificação de sentenças em ptbr (Serras et al., 2026)
 - Baseado no *Córpus Carolina*
 - Anotado por registro (*source_typology*)



Register Variation

VIRTUAL FORUM

ACTIVITIES/EXPERIENCE
SHARING

TWEET

USER PAGE

VIRTUAL
DISCUSSION

JURIDICAL

JURIDICAL REPORT

OPEN COURT
HEARING

PRECEDENTS
BULETIN

INSTRUCTIONAL

TRAVEL GUIDE

EDUCATIONAL
RESOURCES

VOCABULARY ENTRY

JOURNALISTIC


ARTICLE

NEWS

SCIENTIFIC NEWS


SUBTITLE

ENTERTAINMENT





Metodologia

Metodologia




3000 SENTS/REG
250 SENTS/DOC
250 DOCS/REG






- Análise Estatística
 - Análise de Variância (ANOVA): F -Valor, η^2
 - Análise de Variância Multivariada (MANOVA)
 - Wilks's Lambda Λ
 - Pillai's Trace U
 - Hotelling-Lawley Trace T
 - Roy's Greatest Root θ
 - Follow-up: Linear Discriminant Analysis (LDA)
 - Verificação de Suposições




Resultados e Análise




Resultados

RESULTADOS DO ANOVA

Métrica	Compressor	F-Statistic	P-Value	η^2
C_m	(bzip2)	5988.982	< 0.01	0.957
C_m	(gzip)	5957.92	< 0.01	0.957
C_m^*	(bzip2)	3756.886	< 0.01	0.933
C_m^*	(gzip)	1578.462	< 0.01	0.855
C_s	(bzip2)	78.399	< 0.01	0.226
C_s	(gzip)	67.924	< 0.01	0.202




Resultados





REMOVEMOS

C_m^*
 C_m (GZIP)



Results






Results

Metric	Value	P-Value
Wilks' lambda (Λ)	0.035	< 0.01
Pillai's trace (U)	1.128	< 0.01
Hotelling-Lawley trace (T)	22.855	< 0.01
Roy's greatest root (θ)	22.667	< 0.01

Metric	Compressor	LD1	LD2	LD3
C_m	bzip2	4.908	-0.592	-0.154
C_s	bzip2	0.141	-1	0.572
C_s	gzip	-0.007	-0.544	-0.981



Conclusões



Conclusões

01

Métricas baseadas em compressão são sensíveis à variação em registro no Português?

02

Essa variação mantém o *trade-off* entre métricas sintáticas e morfológicas, como observado para o Inglês?

03


Em que medida esses padrões de variação diferem ou se assemelham dos observados para o Inglês?




Referências


- Patrick Juola. 2008. Assessing linguistic complexity, pages 89–108. John Benjamins Publishing Company
- Katharina Ehret and Benedikt Szmrecsanyi. 2016. An information-theoretic approach to assess linguistic complexity, pages 71–94. De Gruyter, Berlin, Boston
- Katharina Ehret. 2016. An information-theoretic approach to language complexity: variation in naturalistic corpora. Ph.D. thesis, Albert-Ludwigs Universität Freiburg.
- Felipe Ribas Serras, Miguel de Mello Carpi, Mariana Lourenço Sturzeneker, Mayara Feliciano Palma, Aline Silva Costa, Vanessa Martins do Monte, Cristiane Namiuti, Maria Clara Ramos Morales Crespo, Maria Clara Paixão de Sousa, and Marcelo Finger. 2026. Automatic analysis and classification of discourse domains in brazilian portuguese. *Linguamática*, 17(2):131–171

Agradecimentos





Obrigado!



- *Setup* Experimental
 - Foco no nível sentencial.
 - Massa Crítica de dados para Nível de compressão.
 - Ehret, 2016 → Entradas com mesmo número de sentenças quando entradas não compartilham conteúdo proposicional